



Métodos Cuantitativos Aplicados a la Investigación

Estadística Descriptiva

Luis Chávez¹

¹Departamento de Economía

Lima, 2026

Contenido

1. Introducción

- 1.1 Conceptos básicos
- 1.2 Fundamentos

2. El proceso de análisis de datos

- 2.1 Definición del problema
- 2.2 Recopilación de datos
- 2.3 Preparación de datos

Introducción

Perú: personal ocupado según segmento empresarial, 2023

Segmento empresarial	Total	%
Total	5 066 366	100.0
Gran empresa	2 590 351	51.1
Mediana empresa	118 904	2.4
Pequeña empresa	1 696 333	33.5
Microempresa ⁽¹⁾	660 778	13.0


Nota: (1) Incluye microempresas con ventas netas $\geq$ 50 UIT.

Fuente: INEI – Encuesta Económica Anual 2024.

¿Dónde estamos?

-  El mundo de la ciencia de datos.
-  Era de los datos masivos (*big data*).
-  Inteligencia artificial.
-  Era digital tecnológica (de la información).
-  Aprendizaje automático (*machine learning*).
-  Analítica de datos.


Conceptos



La estadística transforma datos en información.

La analítica transforma información en conocimiento.

Conceptos



Definición 1

Base de datos (*database*) es una colección de *datasets* almacenados estructuralmente para acceso y actualización frecuente.

Datasets pequeños se almacenan en *spreadsheets* o *flat files* (matrices rectangulares).

Datasets masivos se almacenan en sistemas de bases de datos (relacionales o no).

Conceptos





Figura: El proceso de análisis de datos [Nelli, 2023].

Fundamentos



Definición 2

Estadística es la ciencia que se encarga de obtener, organizar, resumir, presentar, analizar e interpretar datos para resolver una pregunta de investigación [Triola, 2022].

Definición 3

La **unidad de análisis** es el elemento sobre el cual se recolecta información para un estudio.

Definición 4

La **población**, N , es el conjunto de todas las unidades de análisis de interés.

Definición 5

La **muestra**, n , es el subconjunto observado de una población.

Ejemplo 1

El Instituto Nacional de Estadística e Informática (INEI) desea estudiar el nivel de empleo informal en el Perú durante el año 2025. Para ello, realiza una encuesta a hogares en distintas regiones del país. Caracterizar el estudio.

Definición 6

Un **parámetro** es una medida numérica que describe una característica específica de una población.

Definición 7

Un **estadístico** es una medida numérica que describe una característica específica de una muestra.


Ejemplo 2

Un economista desea estimar la tasa promedio de inflación de precios al consumidor en Perú a finales del siglo XX. En INEI, encuentra registros de los años 1980 a 2000, que trata como una muestra de todas las tasas de inflación de finales del siglo XX. La tasa promedio de inflación en los registros es 7.6. Utilizando un método estadístico, estima que la tasa promedio de inflación en Perú a finales del siglo XX estaba entre 7.31 y 7.92.

- a) ¿Qué parte exhibe un resumen descriptivo de los datos?
- b) ¿Qué parte hace una inferencia sobre una población?
- c) ¿A qué población se refiere la inferencia en la parte b?
- d) ¿Es 7.6 un estadístico o un parámetro?

Definición 8

Una **variable** es una característica observada de una unidad de análisis.



Ejemplo 3

Se realiza un estudio del parque automotor en la cuadra 8 de la avenida Salaverry durante 30 días consecutivos. Identifique las variables de análisis y el tipo de cada una.

Python

Python, creado en 1991, será el instrumento de análisis de datos.

- Es *open-source*.
- Ficheros *.py*.
- Una vez que se escribe el código, se requiere de un **intérprete**¹ para ejecutarlo.
- Distribuidores de Python: Anaconda, Miniconda o WinPython.
- IDEs populares: Colab, Spyder, Jupyter Notebook, PyCharm y VS Code.

¹Tales como CPython, PyPy e IPython.

Ejemplo 4

Abrir el fichero [cuaderno0.ipynb](#) en Google Colab y ejecutar los comandos. Analizar e interpretar las salidas.

El proceso de análisis de datos

Definición del problema

- Se describe el contexto en el que surge el problema y su relevancia en el área de estudio.
- Se identifica y formula el problema de investigación, estableciendo qué se desea estudiar, medir o resolver.
- Se identifican las variables relevantes que serán analizadas.
- Se define el alcance del estudio para delimitar el análisis y evitar ambigüedades.

Recopilación de datos

Proceso mediante el cual se obtienen datos relevantes y confiables:

1. Identificación de las fuentes de datos.
2. Selección de técnicas e instrumentos adecuados.
3. Registro y almacenamiento de la información.
4. Calidad de los datos.

Recopilación de datos

① Fuentes de datos

a) Primarias.


b) Secundarias.

- Dataset Search Google.
- Kaggle.
- DataHub.
- NASA.
- World Health Organization.

c) Mixtas.


Recopilación de datos

② Técnicas e instrumentos




Recopilación de datos

② Técnicas e instrumentos



Recopilación de datos

③ Registro y almacenamiento



Recopilación de datos

④ Calidad de los datos

Se evalúa mediante dimensiones [IBM, 2026]:

- **Integridad:** cantidad de datos utilizables o completos
- **Unicidad:** ausencia de registros duplicados.
- **Validez:** cumplimiento de formatos y reglas de negocio.
- **Puntualidad:** disponibilidad de los datos a tiempo.
- **Precisión:** exactitud respecto a fuentes confiables.
- **Consistencia:** coherencia entre diferentes conjuntos de datos.
- **Adecuación al propósito:** utilidad del dato para el objetivo del negocio.

Preparación de datos

Pasos:

1. Integración de datos: recopilar un único conjunto de datos (*dataset*) con información proveniente de diversas fuentes [García et al., 2015].
2. *Data Cleaning*: proceso de detectar, corregir o eliminar errores, inconsistencias y datos sucios² de un conjunto de datos.
3. Transformación de datos: proceso mediante el cual se generan, modifican o reexpresan variables del conjunto de datos para hacerlas más adecuadas al análisis.
4. Reducción de datos: proceso de obtener una representación más compacta de un conjunto de datos, disminuyendo el número de observaciones, variables o valores almacenados, de manera que se preserve la capacidad analítica del conjunto de datos.

²Datos faltantes (*missing data*), *outliers* y representaciones no estándar.

Preparación de datos

① Integración de datos

- Fusión (*merge/join*): en Python la fusión de datos se realiza con la función `pd.merge()`.

Tipo	Factores que se conservan
<code>inner join</code>	Solo si hay coincidencia exacta en ambas tablas.
<code>left join</code>	Todos los de la izquierda; si no hay coincidencia, <i>NaN</i> .
<code>right join</code>	Todos los de la derecha; si no hay coincidencia, <i>NaN</i> .
<code>outer join</code>	Todos los de ambas tablas, coincidan o no.

- Unión (concatenación vertical o *append*): en Python se puede añadir instancias o filas con la función `pd.concat()`.
- Unión (concatenación horizontal): en Python se puede añadir columnas con la función `pd.concat( , axis=1)`. No se recomienda.

Preparación de datos

① Integración de datos

Ejemplo 5

A partir de los datos de la ENAHO (INEI) y el [cuaderno1.ipynb](#), integrar los módulos características de los miembros del hogar, educación y salud.

Preparación de datos

② Data cleaning

- Valores perdidos (*missing values*).
- Imputación.
- Valores atípicos (*outliers*).
- Duplicados.
- Inconsistencias en tipos de datos.

Preparación de datos

② Data cleaning

Ejemplo 6

A partir del conjunto de datos *01clientes.xlsx* y el [cuaderno2.ipynb](#) realizar los procedimientos de limpieza de datos.

Preparación de datos

③ Transformación de datos

- Conversión de tipos de datos.
- Creación de variables.
- Codificación y/o recodificación.
- Discretización.
- Normalización y estandarización.

Preparación de datos

③ Transformación de datos

Definición 9

La **codificación** es el proceso mediante el cual las variables categóricas se transforman en representaciones numéricas, con el fin de ser utilizadas en algoritmos estadísticos y de aprendizaje automático.

Preparación de datos

③ Transformación de datos

Definición 10

La **discretización** es el proceso mediante el cual una variable continua se transforma en un conjunto finito de categorías o intervalos con el objetivo de facilitar su análisis. Es el caso de modelos que trabajan mejor con variables categóricas.

Preparación de datos

③ Transformación de datos

Ejemplo 7

A partir del conjunto de datos *titanic.csv* y el [cuaderno3.ipynb](#) aplicar los procedimientos de transformación de datos. Analizar resultados.

Preparación de datos

④ Reducción de datos

- Selección de variables.
- Selección de instancias.
- Reducción de dimensionalidad.
- Agregación.

Preparación de datos

④ Reducción de datos

Definición 11

La **selección de variables (atributos)** consiste en identificar y conservar únicamente las variables más relevantes para el modelo, eliminando aquellas irrelevantes o redundantes.

Preparación de datos

④ Reducción de datos

Algunos métodos de selección de variables:

- a) **Métodos filter**: seleccionan variables según medidas estadísticas como correlación, chi-cuadrado o información mutua, sin usar modelos predictivos.
- b) **Métodos wrapper (envolvente)**: evalúan subconjuntos de variables usando un modelo predictivo y seleccionan el que mejor rendimiento produce.
- c) **Métodos embedded (incrustados)**: realizan la selección de variables durante el entrenamiento del modelo (ejemplo: Lasso, árboles de decisión).
- d) **Eliminación recursiva de variables (RFE)**: elimina iterativamente las variables menos importantes según el modelo.

Preparación de datos

④ Reducción de datos

Definición 12

La **selección de instancias** (filas) consiste en elegir un subconjunto representativo de observaciones del conjunto de datos original, manteniendo la información más relevante.

Preparación de datos

④ Reducción de datos

Algunos métodos de selección de instancias:

- a) **Random sampling**: selecciona instancias de forma aleatoria del conjunto de datos original.
- b) **Muestreo estratificado**: divide los datos en grupos (estratos) y selecciona muestras representativas de cada uno.
- c) **Selección basada en clustering**: agrupa los datos y selecciona instancias representativas de cada grupo.
- d) **Condensed Nearest Neighbor (CNN)**: elimina instancias redundantes manteniendo las necesarias para preservar la frontera de decisión.
- e) **Undersampling**: elimina instancias de la clase mayoritaria para equilibrarla con la clase minoritaria (balanceo de datos).

Preparación de datos

④ Reducción de datos

Definición 13

La **reducción de dimensionalidad** consiste en disminuir el número de variables del conjunto de datos, manteniendo la mayor cantidad posible de información relevante.

Preparación de datos

④ Reducción de datos

Algunos métodos de reducción de dimensiones:

- a) **Análisis de Componentes Principales (PCA)**: transforma las variables originales en nuevas variables (componentes) que conservan la mayor varianza posible.
- b) **Análisis factorial**: identifica variables latentes que explican las correlaciones entre las variables observadas.
- c) **t-SNE**: método no lineal usado principalmente para visualización en 2D o 3D.
- d) **UMAP**: técnica moderna que preserva la estructura global y local de los datos.

Preparación de datos

④ Reducción de datos

Ejemplo 8

Utilizando el [cuaderno4.ipynb](#) realizar la reducción de datos del conjunto de datos *02housing.csv*. Analizar e interpretar resultados.

References

-  García, S., Luengo, J., and Herrera, F. (2015).
Data Preprocessing in Data Mining.
Springer.
-  IBM (2026).
What is data quality?
Accessed: 2026-05-12.
-  Nelli, F. (2023).
Python Data Analytics: With Pandas, NumPy, and Matplotlib.
Apress, Berkeley, CA, 3 edition.
-  Triola, M. F. (2022).
Elementary Statistics.
Pearson, 14 edition.