



Métodos Cuantitativos Aplicados a la Investigación

Exploración y visualización de datos

Luis Chávez¹

¹Departamento de Economía

Lima, 2026

Contenido

1. Estadística descriptiva

- 1.1 Medidas de localización
- 1.2 Medidas de distribución

2. Índices y análisis temporal

- 2.1 Números índice
- 2.2 Series temporales

3. Visualización de datos

- 3.1 Univariados
- 3.2 Bivariados

4. Introducción a minería de datos

- 4.1 Fundamentos
- 4.2 Clustering
- 4.3 Clasificación
- 4.4 Text mining

Estadística descriptiva

Medidas de tendencia central

Definición 1

La **media** o promedio aritmético de x es la suma de observaciones de una variable ponderado por el número de datos.

$$\bar{x} = \frac{\sum x_i}{n}, \quad \forall i = 1, \dots, n \quad (1)$$

$$\mu = \frac{\sum x_i}{N}, \quad \forall i = 1, \dots, N \quad (2)$$

Medidas de tendencia central

Definición 2

La **media truncada** o *trimmed mean* es una medida que se obtiene eliminando un porcentaje de las observaciones más pequeñas y más grandes antes de calcular la media. Si $x_1 \leq x_2 \leq \dots \leq x_n$ es el conjunto ordenado de datos,

$$\bar{x}_t = \frac{1}{n - 2k} \sum_{i=k+1}^{n-k} x_i \quad (3)$$

donde $k = \lfloor pn \rfloor$ y p es la proporción de datos eliminados en cada extremo.

Medidas de tendencia central

Definición 3

La **mediana** (me) representa el valor central de un conjunto de datos ordenados en forma ascendente o descendente (si n es impar). Si n es par, se utiliza la semisuma de los valores centrales.

Medidas de tendencia central

Definición 4

La **moda** (*mo*) de una variable x es(son) el(los) valor(es) que tiene(n) mayor frecuencia.

Medidas de tendencia central

Definición 5

La **mitad de rango** (mr) de una variable x es la semisuma entre los valores máximo y mínimo.

$$mr = \frac{max + min}{2} \quad (4)$$

Medidas de tendencia central

Ejemplo 1

Los dorsales asignados a los jugadores del Paris Saint-Germain para la final de la Champions League 2026 fueron:

2, 4, 5, 6, 7, 8, 9, 10, 14, 17, 19, 21, 23, 24, 25, 27, 29, 30, 33, 39, 47, 49, 51, 89

Indique y justifique cuál es la medida de tendencia central más apropiada.

Medidas de posición

Nota 1

Para el cálculo de cuantiles, R, Python y Julia utilizan el método de interpolación lineal *type 7* de Hyndman and Fan (1996).

Definición 6

Los **cuantiles** (Q_i) dividen un conjunto de datos ordenados en cuatro partes aproximadamente iguales. El cuartil i es el valor por debajo del cual se encuentra aproximadamente el $25i\%$ de las observaciones. La posición del i -ésimo cuartil es:

$$pos(Q_i) = 1 + (n - 1)\frac{i}{4}, \quad i = 1, 2, 3 \quad (5)$$

Medidas de posición

Definición 7

Los **quintiles** (K_i) dividen un conjunto de datos ordenados en cinco partes aproximadamente iguales. El quintil i es el valor por debajo del cual se encuentra aproximadamente el $20i\%$ de las observaciones. La posición del i -ésimo quintil es:

$$pos(Q_i) = 1 + (n - 1)\frac{i}{5}, \quad i = 1, \dots, 4 \quad (6)$$

Medidas de posición

Definición 8

Los **deciles** (D_i) dividen un conjunto de datos ordenados en diez partes aproximadamente iguales. El decil i es el valor por debajo del cual se encuentra aproximadamente el $10i\%$ de las observaciones. La posición del i -ésimo decil es:

$$pos(Q_i) = 1 + (n - 1)\frac{i}{10}, \quad i = 1, \dots, 9 \quad (7)$$


Medidas de posición

Definición 9

Los **percentiles** (P_i) dividen un conjunto de datos ordenados en cien partes aproximadamente iguales. El percentil i es el valor por debajo del cual se encuentra aproximadamente el $i\%$ de las observaciones. La posición del i -ésimo percentil es:

$$pos(Q_i) = 1 + (n - 1) \frac{i}{100}, \quad i = 1, \dots, 99 \quad (8)$$

Medidas de posición



Medidas de posición

Ejemplo 2

Los tiempos de espera (en minutos) de un grupo de 20 personas para ser atendidas en un banco son:

2, 3, 4, 5, 6, 7, 8, 9, 10, 10, 11, 13, 14, 15, 16, 18, 20, 22, 25, 30

Hallar manualmente los cuartiles y P_{35} .

Medidas de variación

Definición 10

El **rango** (ran) de una variable x es la diferencia entre su valor máximo y su valor mínimo.

$$ran = max - min \quad (9)$$

Medidas de variación

Definición 11

La **desviación estándar** de una variable x mide la desviación de los datos respecto a su media.

$$s = \sqrt{\frac{\sum (x - \bar{x})^2}{n - 1}} \quad (10)$$

$$\sigma = \sqrt{\frac{\sum (x - \mu)^2}{N}} \quad (11)$$


Medidas de variación

Propiedades de s :

- $s \geq 0$.
- Sensible a valores atípicos.
- Tiene la misma unidad de medida que los datos originales.
- s es un estimador sesgado de σ .
- Regla práctica:

$$s \equiv \frac{ran}{4}$$

Medidas de variación



Regla empírica en una distribución normal

Medidas de variación

Definición 12

La **varianza** de una variable x mide el promedio de las distancias al cuadrado entre cada valor y su media.

$$s^2 = \frac{\sum (x - \bar{x})^2}{n - 1} \quad (12)$$

$$\sigma^2 = \frac{\sum (x - \mu)^2}{N} \quad (13)$$

Definición 13

El **coeficiente de variación** es una medida adimensional que cuantifica la variabilidad relativa de los datos en relación con su media aritmética.

$$cv_m = \frac{s}{\bar{x}} \quad (14)$$

$$cv_p = \frac{\sigma}{\mu} \quad (15)$$

Medidas de variación

Definición 14

La **desviación media absoluta** (MAD) es una medida de variación que cuantifica el promedio de las desviaciones absolutas respecto a la media aritmética.

$$MAD_m = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}| \quad (16)$$

$$MAD_p = \frac{1}{N} \sum_{i=1}^N |x_i - \mu| \quad (17)$$

Definición 15

La **mediana absoluta de la desviación** es una medida robusta de dispersión que cuantifica la variabilidad de los datos respecto a la mediana, siendo altamente resistente a valores atípicos.

$$MAD_r = me(|x_i - me(x)|) \quad (18)$$

Medidas de variación

Ejemplo 3

Las edades (en años) al momento de asumir la Presidencia de la República del Perú de los mandatarios que ejercieron funciones desde el año 2000 fueron:

83, 38, 60, 51, 76, 59, 55, 77, 49, 57, 55, 64

Determine cuál de las medidas de variación captura adecuadamente la heterogeneidad de los datos.

Definición 16

La **asimetría** (A) o sesgo mide el grado de simetría de una distribución de datos respecto a su media.

- $A \approx 0$: distribución simétrica.
- $A > 0$: asimetría positiva (cola a la derecha).
- $A < 0$: asimetría negativa (cola a la izquierda).
- Si la distribución de los datos es simétrica, $\bar{x} = mo = me$. Si es sesgada en la derecha $mo < me < \bar{x}$ en cambio, si es sesgada en la izquierda $\bar{x} < me < mo$.

Medidas de forma

- Asimetría de Fisher:

$$A_F = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3}{s^3} \quad (19)$$

- Asimetría de Pearson:

$$A_P = \frac{3(\bar{x} - me)}{s} \quad (20)$$

- Asimetría de Bowley:

$$A_B = \frac{Q_3 + Q_1 - 2Q_2}{Q_3 - Q_1} \quad (21)$$

- Asimetría de Kelly:

$$A_K = \frac{P_{90} + P_{10} - 2P_{50}}{P_{90} - P_{10}} \quad (22)$$

Medidas de forma

- Asimetría de Fisher:

$$\gamma_1 = \frac{\mathbb{E}[(X - \mu)^3]}{\sigma^3} \quad (23)$$

- Asimetría de Pearson:

$$A_P = \frac{3(\mu - me)}{\sigma} \quad (24)$$

- Asimetría de Bowley:

$$A_B = \frac{Q_3 + Q_1 - 2Q_2}{Q_3 - Q_1} \quad (25)$$

- Asimetría de Kelly:

$$A_K = \frac{P_{90} + P_{10} - 2P_{50}}{P_{90} - P_{10}} \quad (26)$$

Definición 17

La **curtosis** (K) describe la forma de la distribución, en particular, el peso de las colas de la distribución y -en menor medida- el grado de concentración de los datos alrededor de la media.

- Es una medida adimensional.
- La interpretación depende del coeficiente utilizado.
- Es sensible a valores atípicos.
- Es invariante ante cambios de origen y escala.

Medidas de forma

Curtosis de Pearson:

$$K_P = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^4}{s^4} \quad (27)$$

$$\beta_2 = \frac{\mathbb{E}[(X - \mu)^4]}{\sigma^4} \quad (28)$$

- $K_P > 3$: distribución **leptocúrtica** (mayor concentración central y colas pesadas).
- $K_P = 3$: distribución **mesocúrtica** (similar a la normal).
- $K_P < 3$: distribución **platicúrtica** (menor concentración central y colas ligeras).

Medidas de forma

Exceso de curtosis de Fisher:

$$\gamma_2 = \frac{\mathbb{E}[(X - \mu)^4]}{\sigma^4} - 3 \quad (29)$$

$$K_F = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^4}{s^4} - 3 \quad (30)$$

- $K > 0$: distribución leptocúrtica.
- $K = 0$: distribución mesocúrtica.
- $K < 0$: distribución platicúrtica.

Medidas de forma

Coeficiente de curtosis de Moors:

$$K_M = \frac{(O_7 - O_5) + (O_3 - O_1)}{O_6 - O_2} \quad (31)$$

donde O es un octil.

- Valores mayores del coeficiente indican una mayor concentración de los datos alrededor del centro y colas relativamente más pesadas.
- Se utiliza principalmente para comparar distribuciones.
- Es menos sensible a valores atípicos.

Ejemplo 4

A partir del conjunto de datos *04titanic_tr.csv* y [cuaderno5.ipynb](#) calcular las medidas descriptivas apropiadas. Interpretar los resultados.

Anexo 1

Distribución de frecuencias

1. Establecer el número de clases, k usando la regla de Sturges (1926):

$$k = 1 + 3.322 * \ln(n)$$

2. Calcular el ancho o amplitud de clase, w

$$w = \frac{ran}{k}$$

3. Establecer los límites inferior y superior de cada clase.
4. Hallar las marcas de clase, m .
5. Hallar frecuencias absolutas y relativas.

Índices y análisis temporal

Números índice

Definición 18

Los **números índice** son una medida relativa, expresada en términos porcentuales, que compara los valores de una variable medidos en diferentes momentos (o espacios), en relación con un período (o espacio) de referencia.

Números índice

Taxonomía:

1. Según variables:

- Índices simples: miden la variación relativa de una sola variable entre dos períodos (o espacios).
- Índices compuestos: miden la variación relativa conjunta de dos o más variables entre dos períodos (o espacios).

2. Según naturaleza:

- Índices de precios.
- Índices de cantidades.
- Índices de valor.

Definición 19

Si x_t es la medición de una variable computada en el tiempo t y x_0 es dicha variable pero computada en el tiempo 0 (tiempo base), el **índice simple** de x para el tiempo t con respecto al tiempo 0 es

$$I_0^t(x) = \frac{x_t}{x_0} \times 100 \% \quad (32)$$

donde x puede ser un precio, cantidad o valor.

Números índice

Ejemplo 5

Se registró el salario mensual de un trabajador durante los siguientes años. Se halló los índices para evaluar el incremento/disminución.

t	salario (S/.)	2015=100	2019=100
2015	1200	100.0	46.2
2016	1450	120.8	55.8
2017	1750	145.8	67.3
2018	2200	183.3	84.6
2019	2600	216.7	100.0

Números índice

Propiedades (índice simple)

1. Existencia. El índice debe existir y ser un número real positivo.
2. Identidad. Cuando el período actual coincide con el período base, el número índice debe ser 1.
3. Inversión. Al intercambiar el período base y el período actual, el índices debe ser su recíproco.
4. Proporcionalidad. Si todos los valores del período actual se multiplican por una constante positiva k , el número índice debe variar afectado por k .
5. Homogeneidad. El índice es invariante ante cambios de unidades de medida.

Números índice

Índices compuestos no ponderados:

Definición 20

El **índice agregado simple** compara el valor total de una variable en el período actual con el valor total en el período base, sin asignar ponderaciones:

$$I_0^t(x) = \frac{\sum_{i=1}^n x_{it}}{\sum_{i=1}^n x_{i0}} \times 100 \% \quad (33)$$

donde x_{it} y x_{i0} representan el valor de la variable para el bien i en los períodos t y 0 , respectivamente.

Números índice

Índices compuestos ponderados:

Definición 21

Los **índices compuestos ponderados** comparan el nivel de una variable entre dos períodos utilizando varias observaciones, asignando a cada una un peso que refleja su importancia relativa. Las ponderaciones usadas para índices compuestos de precios (cantidades) son las cantidades de los bienes o ítems, mientras que las ponderaciones para el índices de cantidades agregadas son los precios de los bienes del año base.

Números índice

- **Índice de precios de Laspeyres:**

$$I_0^t(p_L) = \frac{\sum_{i=1}^n p_{it}q_{i0}}{\sum_{i=1}^n p_{i0}q_{i0}} \times 100 \quad (34)$$

- **Índice de precios de Paasche:**

$$I_0^t(p_P) = \frac{\sum_{i=1}^n p_{it}q_{it}}{\sum_{i=1}^n p_{i0}q_{it}} \times 100 \quad (35)$$

- **Índice de precios de Fisher:**

$$I_F = \sqrt{I_0^t(p_L) \times I_0^t(p_P)} \quad (36)$$

Números índice

- **Índice de cantidades de Laspeyres:**

$$I_0^t(q_L) = \frac{\sum_{i=1}^n p_{i0} q_{it}}{\sum_{i=1}^n p_{i0} q_{i0}} \times 100 \quad (37)$$

- **Índice de cantidades de Paasche:**

$$I_0^t(q_P) = \frac{\sum_{i=1}^n p_{it} q_{it}}{\sum_{i=1}^n p_{it} q_{i0}} \times 100 \quad (38)$$

- **Índice de cantidades de Fisher:**

$$I_F = \sqrt{I_0^t(q_L) \times I_0^t(q_P)} \quad (39)$$

Series temporales

Definición 22

Una **serie temporal** es un conjunto de observaciones de una variable registradas de forma secuencial en el tiempo y ordenadas cronológicamente.

Series temporales

Descomposición:

- Tendencia (T): movimiento de largo plazo que refleja la dirección general de la serie.
- Estacionalidad (S): variaciones periódicas que se repiten en intervalos regulares (meses, trimestres, etc.).
- Ciclo (C): fluctuaciones de mediano y largo plazo asociadas al comportamiento económico.
- Componente irregular (I): variaciones aleatorias ocasionadas por eventos inesperados.

$$Y_t = T_t + S_t + C_t + I_t \quad (40)$$

$$Y_t = T_t \times S_t \times C_t \times I_t \quad (41)$$

Definición 23

Las series temporales pueden registrarse en distintas **frecuencias**, dependiendo del nivel de desagregación y disponibilidad de la información.

La frecuencia afecta:

- La detección de estacionalidad.
- La variabilidad de la serie.
- La construcción de indicadores comparables.

Series temporales

Definición 24

Una **variable stock** es aquella que se mide en un momento específico del tiempo (fotografía). Su valor no depende de un período, sino de un instante puntual, por lo que no se acumula entre períodos.

Definición 25

Una **variable flujo** es aquella que se mide a lo largo de un período de tiempo. Su valor resulta de la acumulación durante ese período, por lo que es aditiva.

Desagregación...

Definición 26

El **empalme** es un procedimiento estadístico que permite unir dos o más series que presentan cambios metodológicos, de base o de cobertura, con el fin de construir una única serie homogénea y comparable en el tiempo.

Series temporales

En la práctica, existe problemas de:

- Año base.
- Metodología de cálculo.
- Cobertura de la muestra.

Esto genera rupturas en la serie temporal.

Series temporales

Métodos de empalme:

- **Método de razón:** ajusta una serie usando el cociente entre periodos comunes.
- **Método de diferencia:** ajusta mediante la diferencia promedio entre series en el periodo de solapamiento.
- **Empalme por índices:** convierte ambas series a índices base 100 y luego las une.

Definición 27

La **retropolación** es un procedimiento que permite estimar valores de una serie en períodos anteriores a partir de una serie actual, utilizando factores de enlace o relaciones de empalme entre ambas series.

Definición 28

El **cambio de año base** consiste en modificar el período de referencia de un índice (base = 100), con el fin de actualizar su estructura, metodología o periodo de comparación sin alterar la dinámica de la serie.

Ejemplo 6

A partir del [cuaderno6.ipynb](#), evaluar e interpretar los resultados obtenidos en el cálculo de números índice y en la aplicación de los métodos de análisis de series temporales.

Visualización de datos

Aplicación

Ejemplo 7

A partir del [cuaderno7.ipynb](#) y los datos *03titanic_tr.parquet* interpretar los gráficos univariados.

Aplicación

Ejemplo 8

A partir del [cuaderno7.ipynb](#) y los datos *03titanic_tr.parquet* interpretar los gráficos bivariados.


Introducción a minería de datos

Definición 29

La **minería de datos**, a veces *Knowledge Discovery from Data* (KDD), es el proceso de descubrir patrones, modelos y otros tipos de conocimiento interesantes en grandes conjuntos de datos Han et al., 2022.

Fundamentos

The Knowledge Discovery Process (KDD)



Fundamentos

Tipos:

1. Datos estructurados.

- Poseen un esquema fijo (filas y columnas).
- Se almacenan en bases de datos relacionales.
- Ejemplos: registros de clientes, transacciones, hojas de cálculo.


2. Datos semiestructurados.

- Presentan una estructura flexible basada en etiquetas o metadatos.
- No requieren un esquema rígido.
- Ejemplos: XML, JSON, HTML, archivos de registro (logs).

3. Datos no estructurados.

- Carecen de un esquema predefinido.
- Su contenido es principalmente textual o multimedia.
- Ejemplos: documentos de texto, mails, imágenes, audio y video.

Fundamentos



Aplicaciones de DM:


- Business intelligence.
- Web search engines.
- Social media and social networks.
- Healthcare Analytics.
- Cybersecurity.
- Predictive Maintenance.
- ...

Clustering

Definición 30

El agrupamiento o **clustering** es el proceso de organizar un conjunto de elementos en varios grupos o conglomerados, de modo que los objetos dentro de un mismo grupo presenten una gran similitud entre sí (cohesión), pero difieran de los objetos de otros grupos (separación).

Clustering



Definición 31

El **clustering de partición** divide un conjunto de n observaciones en k clústeres ($k \leq n$), donde cada clúster contiene al menos un elemento y cada observación se asigna a un único grupo. Su objetivo es obtener particiones con alta similitud dentro de cada clúster y baja similitud entre clústeres (Han et al., 2022).

Clustering

Algoritmos importantes:

- Basados en centroides:
 - *K-Means*.
 - *Fuzzy C-Means* (FCM).
- Basados en medoides:
 - PAM.
 - CLARA (*Clustering Large Applications*).
 - CLARANS (*Clustering Large Applications based on Randomized Search*).

Definición 32

El **clustering jerárquico** construye una estructura jerárquica de clústeres, uniendo progresivamente los grupos más similares (enfoque aglomerativo o *bottom-up*) o dividiendo sucesivamente un grupo grande en subgrupos (enfoque divisivo o *top-down*) (Han et al., 2022).

Clustering

Algoritmos importantes:

- Métodos aglomerativos:
 - *Single Linkage*
 - *Complete Linkage*
 - *Average Linkage (UPGMA)*
 - *Ward*
 - *Centroid Linkage*
- Métodos divisivos:
 - *DIANA (divisive analysis).*
 - *Bisecting K-Means.*

Definición 33

El **clustering basado en densidad** identifica clústeres como regiones de alta densidad de objetos, separadas por regiones de baja densidad. El enfoque permite descubrir clústeres de forma arbitraria y distinguir el ruido o los valores atípicos.

Clustering

Algoritmos importantes:

- DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*).
- OPTICS (*Ordering Points To Identify the Clustering Structure*).
- HDBSCAN (*Hierarchical Density-Based Spatial Clustering*).
- DENCLUE (*Density-based Clustering*).
- ST-DBSCAN (*Spatio-Temporal DBSCAN*).

Clustering

Ejemplo 9

A partir del [cuaderno8.ipynb](#) y los datos *01clientes.xlsx* establecer el número apropiado de clusters y analizar cada uno de ellos.

Clasificación


¿Por qué utilizar clasificación?

- ¿El cliente comprará el producto?
- ¿El proyecto será rentable?
- ¿La empresa incumplirá el crédito?
- ¿El riesgo será alto, medio o bajo?
- ¿El estudiante desertará?

Definición 34

La **clasificación** es un proceso de aprendizaje supervisado mediante el cual se construye un modelo (clasificador) a partir de un conjunto de datos previamente etiquetados, con el propósito de predecir la clase o categoría de nuevos registros cuyos valores de clase son desconocidos (Han et al., 2022).

Clasificación



Clasificación

Técnicas:

- Árboles de decisión: CART, C4.5, C5.0.
- Clasificadores bayesianos: aive Bayes, Bayesian Network.
- Basados en instancia: k-Nearest Neighbors (kNN).
- Basados en reglas: RIPPER, PART, OneR.
- Redes neuronales: Multilayer Perceptron (MLP), Deep Neural Networks.
- Máquinas de soporte vectorial: Support Vector Machine (SVM).
- Métodos ensamblados: Random Forest, AdaBoost, Gradient Boosting, XGBoost.

Ejemplo 10

A partir del [cuaderno8.ipynb](#) y la base de datos *01clientes.xlsx*, construya un modelo de árbol de decisión e identifique las variables con mayor importancia en la clasificación.

Definición 35

La **minería de texto** es el proceso de extraer conocimiento útil a partir de datos no estructurados, como documentos, encuestas, redes sociales y opiniones de usuarios, mediante técnicas de procesamiento del lenguaje natural y aprendizaje automático.

Text mining

Etapas:

1. Tokenización (dividir el texto en palabras).
2. Eliminación de stopwords (palabras sin significado).
3. Normalización (minúsculas, limpieza de símbolos).
4. Lematización o stemming.
5. Construcción del corpus.

Text mining

Aplicaciones:

- Recuperación de información (Information Retrieval).
- Procesamiento de lenguaje natural (NLP).
- Extracción de información, extracción de relaciones.
- Categorización/Clasificación de texto.
- Clustering (agrupamiento).
- Sumarización de texto.
- Análisis de enlaces y estructura visual.

Ejemplo 11

A partir del [cuaderno9.ipynb](#) analice el mensaje presidencial de la ex presidente Dina Boluarte. Grafique palabras claves.

References

- Han, J., Pei, J., and Tong, H. (2022). *Data Mining: Concepts and Techniques*. Morgan Kaufmann, 4 edition.
- Hyndman, R. J. and Fan, Y. (1996). Sample quantiles in statistical packages. *The American Statistician*, 50(4):361–365.