



Métodos Cuantitativos Aplicados a la Investigación

Exploración y visualización de datos

Luis Chávez¹

¹Departamento de Economía

Lima, 2026

Contenido

1. Estadística descriptiva

- 1.1 Medidas de localización
- 1.2 Medidas de distribución

2. Índices y análisis temporal

- 2.1 Números índice
- 2.2 Series temporales

3. Visualización de datos

- 3.1 Distribuciones
- 3.2 Comparación de grupos
- 3.3 Relación y correlación

4. Introducción a minería de datos

- 4.1 Clustering
- 4.2 Detección de riesgos y anomalías
- 4.3 Predicciones y pronósticos

Estadística descriptiva

Medidas de tendencia central

Definición 1

La **media** o promedio aritmético de x es la suma de observaciones de una variable ponderado por el número de datos.

$$\bar{x} = \frac{\sum x_i}{n}, \quad \forall i = 1, \dots, n \quad (1)$$

$$\mu = \frac{\sum x_i}{N}, \quad \forall i = 1, \dots, N \quad (2)$$

Medidas de tendencia central

Definición 2

La **media truncada** o *trimmed mean* es una medida que se obtiene eliminando un porcentaje de las observaciones más pequeñas y más grandes antes de calcular la media. Si $x_1 \leq x_2 \leq \dots \leq x_n$ es el conjunto ordenado de datos,

$$\bar{x}_t = \frac{1}{n - 2k} \sum_{i=k+1}^{n-k} x_i \quad (3)$$

donde $k = \lfloor pn \rfloor$ y p es la proporción de datos eliminados en cada extremo.

Medidas de tendencia central

Definición 3

La **mediana** (me) representa el valor central de un conjunto de datos ordenados en forma ascendente o descendente (si n es impar). Si n es par, se utiliza la semisuma de los valores centrales.

Medidas de tendencia central

Definición 4

La **moda** (*mo*) de una variable x es(son) el(los) valor(es) que tiene(n) mayor frecuencia.

Medidas de tendencia central

Definición 5

La **mitad de rango** (mr) de una variable x es la semisuma entre los valores máximo y mínimo.

$$mr = \frac{max + min}{2} \quad (4)$$

Medidas de tendencia central

Ejemplo 1

Los dorsales asignados a los jugadores del Paris Saint-Germain para la final de la Champions League 2026 fueron:

2, 4, 5, 6, 7, 8, 9, 10, 14, 17, 19, 21, 23, 24, 25, 27, 29, 30, 33, 39, 47, 49, 51, 89

Indique y justifique cuál es la medida de tendencia central más apropiada.

Medidas de posición

Nota 1

Para el cálculo de cuantiles, R, Python y Julia utilizan el método de interpolación lineal *type 7* de Hyndman and Fan (1996).

Definición 6

Los **cuantiles** (Q_i) dividen un conjunto de datos ordenados en cuatro partes aproximadamente iguales. El cuartil i es el valor por debajo del cual se encuentra aproximadamente el $25i\%$ de las observaciones. La posición del i -ésimo cuartil es:

$$pos(Q_i) = 1 + (n - 1)\frac{i}{4}, \quad i = 1, 2, 3 \quad (5)$$

Medidas de posición

Definición 7

Los **quintiles** (K_i) dividen un conjunto de datos ordenados en cinco partes aproximadamente iguales. El quintil i es el valor por debajo del cual se encuentra aproximadamente el $20i\%$ de las observaciones. La posición del i -ésimo quintil es:

$$pos(Q_i) = 1 + (n - 1)\frac{i}{5}, \quad i = 1, \dots, 4 \quad (6)$$

Medidas de posición

Definición 8

Los **deciles** (D_i) dividen un conjunto de datos ordenados en diez partes aproximadamente iguales. El decil i es el valor por debajo del cual se encuentra aproximadamente el $10i\%$ de las observaciones. La posición del i -ésimo decil es:

$$pos(Q_i) = 1 + (n - 1)\frac{i}{10}, \quad i = 1, \dots, 9 \quad (7)$$


Medidas de posición

Definición 9

Los **percentiles** (P_i) dividen un conjunto de datos ordenados en cien partes aproximadamente iguales. El percentil i es el valor por debajo del cual se encuentra aproximadamente el $i\%$ de las observaciones. La posición del i -ésimo percentil es:

$$pos(Q_i) = 1 + (n - 1) \frac{i}{100}, \quad i = 1, \dots, 99 \quad (8)$$

Medidas de posición



Medidas de posición

Ejemplo 2

Los tiempos de espera (en minutos) de un grupo de 20 personas para ser atendidas en un banco son:

2, 3, 4, 5, 6, 7, 8, 9, 10, 10, 11, 13, 14, 15, 16, 18, 20, 22, 25, 30

Hallar manualmente los cuartiles y P_{35} .

Medidas de variación

Definición 10

El **rango** (ran) de una variable x es la diferencia entre su valor máximo y su valor mínimo.

$$ran = max - min \quad (9)$$

Medidas de variación

Definición 11

La **desviación estándar** de una variable x mide la desviación de los datos respecto a su media.

$$s = \sqrt{\frac{\sum (x - \bar{x})^2}{n - 1}} \quad (10)$$

$$\sigma = \sqrt{\frac{\sum (x - \mu)^2}{N}} \quad (11)$$


Medidas de variación

Propiedades de s :

- $s \geq 0$.
- Sensible a valores atípicos.
- Tiene la misma unidad de medida que los datos originales.
- s es un estimador sesgado de σ .
- Regla práctica:

$$s \equiv \frac{ran}{4}$$

Medidas de variación



Regla empírica en una distribución normal

Medidas de variación

Definición 12

La **varianza** de una variable x mide el promedio de las distancias al cuadrado entre cada valor y su media.

$$s^2 = \frac{\sum (x - \bar{x})^2}{n - 1} \quad (12)$$

$$\sigma^2 = \frac{\sum (x - \mu)^2}{N} \quad (13)$$

Definición 13

El **coeficiente de variación** es una medida adimensional que cuantifica la variabilidad relativa de los datos en relación con su media aritmética.

$$cv_m = \frac{s}{\bar{x}} \quad (14)$$

$$cv_p = \frac{\sigma}{\mu} \quad (15)$$

Medidas de variación

Definición 14

La **desviación media absoluta** (MAD) es una medida de variación que cuantifica el promedio de las desviaciones absolutas respecto a la media aritmética.

$$MAD_m = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}| \quad (16)$$

$$MAD_p = \frac{1}{N} \sum_{i=1}^N |x_i - \mu| \quad (17)$$

Definición 15

La **mediana absoluta de la desviación** es una medida robusta de dispersión que cuantifica la variabilidad de los datos respecto a la mediana, siendo altamente resistente a valores atípicos.

$$MAD_r = me(|x_i - me(x)|) \quad (18)$$

Medidas de variación

Ejemplo 3

Las edades (en años) al momento de asumir la Presidencia de la República del Perú de los mandatarios que ejercieron funciones desde el año 2000 fueron:

83, 38, 60, 51, 76, 59, 55, 77, 49, 57, 55, 64

Determine cuál de las medidas de variación captura adecuadamente la heterogeneidad de los datos.

Definición 16

La **asimetría** (A) o sesgo mide el grado de simetría de una distribución de datos respecto a su media.

- $A \approx 0$: distribución simétrica.
- $A > 0$: asimetría positiva (cola a la derecha).
- $A < 0$: asimetría negativa (cola a la izquierda).
- Si la distribución de los datos es simétrica, $\bar{x} = mo = me$. Si es sesgada en la derecha $mo < me < \bar{x}$ en cambio, si es sesgada en la izquierda $\bar{x} < me < mo$.

Medidas de forma

- Asimetría de Fisher:

$$A_F = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3}{s^3} \quad (19)$$

- Asimetría de Pearson:

$$A_P = \frac{3(\bar{x} - me)}{s} \quad (20)$$

- Asimetría de Bowley:

$$A_B = \frac{Q_3 + Q_1 - 2Q_2}{Q_3 - Q_1} \quad (21)$$

- Asimetría de Kelly:

$$A_K = \frac{P_{90} + P_{10} - 2P_{50}}{P_{90} - P_{10}} \quad (22)$$

Medidas de forma

- Asimetría de Fisher:

$$\gamma_1 = \frac{\mathbb{E}[(X - \mu)^3]}{\sigma^3} \quad (23)$$

- Asimetría de Pearson:

$$A_P = \frac{3(\mu - me)}{\sigma} \quad (24)$$

- Asimetría de Bowley:

$$A_B = \frac{Q_3 + Q_1 - 2Q_2}{Q_3 - Q_1} \quad (25)$$

- Asimetría de Kelly:

$$A_K = \frac{P_{90} + P_{10} - 2P_{50}}{P_{90} - P_{10}} \quad (26)$$

Definición 17

La **curtosis** (K) describe la forma de la distribución, en particular, el peso de las colas de la distribución y -en menor medida- el grado de concentración de los datos alrededor de la media.

- Es una medida adimensional.
- La interpretación depende del coeficiente utilizado.
- Es sensible a valores atípicos.
- Es invariante ante cambios de origen y escala.

Medidas de forma

Curtosis de Pearson:

$$K_P = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^4}{s^4} \quad (27)$$

$$\beta_2 = \frac{\mathbb{E}[(X - \mu)^4]}{\sigma^4} \quad (28)$$

- $K_P > 3$: distribución **leptocúrtica** (mayor concentración central y colas pesadas).
- $K_P = 3$: distribución **mesocúrtica** (similar a la normal).
- $K_P < 3$: distribución **platicúrtica** (menor concentración central y colas ligeras).

Medidas de forma

Exceso de curtosis de Fisher:

$$\gamma_2 = \frac{\mathbb{E}[(X - \mu)^4]}{\sigma^4} - 3 \quad (29)$$

$$K_F = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^4}{s^4} - 3 \quad (30)$$

- $K > 0$: distribución leptocúrtica.
- $K = 0$: distribución mesocúrtica.
- $K < 0$: distribución platicúrtica.

Medidas de forma

Coeficiente de curtosis de Moors:

$$K_M = \frac{(O_7 - O_5) + (O_3 - O_1)}{O_6 - O_2} \quad (31)$$

donde O es un octil.

- Valores mayores del coeficiente indican una mayor concentración de los datos alrededor del centro y colas relativamente más pesadas.
- Se utiliza principalmente para comparar distribuciones.
- Es menos sensible a valores atípicos.

Ejemplo 4

A partir del conjunto de datos *04titanic_tr.csv* y [cuaderno5.ipynb](#) calcular las medidas descriptivas apropiadas. Interpretar los resultados.

Anexo 1

Distribución de frecuencias

1. Establecer el número de clases, k usando la regla de Sturges (1926):

$$k = 1 + 3.322 * \ln(n)$$

2. Calcular el ancho o amplitud de clase, w

$$w = \frac{ran}{k}$$

3. Establecer los límites inferior y superior de cada clase.
4. Hallar las marcas de clase, m .
5. Hallar frecuencias absolutas y relativas.

Índices y análisis temporal

Visualización de datos

Introducción a minería de datos

References

Hyndman, R. J. and Fan, Y. (1996). Sample quantiles in statistical packages. *The American Statistician*, 50(4):361–365.