



Métodos Cuantitativos Aplicados a la Investigación

Regresión y Correlación

Luis Chávez¹

¹Departamento de Economía

Lima, 2026

Contenido

1. Correlación

2. Regresión lineal simple

2.1 El modelo

2.2 OLS

3. Regresión lineal múltiple

3.1 El modelo

3.2 Estimación

4. Evaluación de modelos

4.1 Bondad de ajuste

4.2 Pruebas estadísticas

Correlación

Correlación

Relaciones

La **relación** entre dos o más variables puede ser funcional (matemática) o estadística.

Correlación

Definición 1

La **correlación** mide la dirección y el grado de relación (estadística) entre dos variables.

Un diagrama de dispersión puede mostrar visualmente la relación entre dos variables.

Correlación

Tipo de variables	Coeficiente	Uso principal
continua - continua (lineal)	Pearson (r)	Mide la intensidad de una relación lineal.
continua - continua (monótona)	Spearman (ρ)	Correlación basada en rangos; robusta a valores atípicos.
ordinal- ordinal	Kendall (τ)	Mide la concordancia entre pares de observaciones.
controlando otras variables	Correlación parcial	Mide la asociación eliminando el efecto de otras variables.
mediciones repetidas	ICC (Intraclass)	Evalúa la consistencia entre mediciones o evaluadores.
relación no lineal	Información mutua	Detecta cualquier tipo de dependencia estadística.

Correlación

Tipo de variables	Coeficiente	Uso principal
nominal - nominal	Cramér (V)	Mide la asociación entre variables categóricas.
binaria - binaria	Phi (ϕ)	Caso particular para tablas 2×2 .
ordinal - ordinal	Policórica	Estima la asociación entre variables ordinales.
binaria - continua	Point-biserial	Una variable continua y la otra dicotómica.
ordinal/binaria - continua	Biserial / Poliserial	Cuando una variable categórica proviene de una continua.

Regresión lineal simple

El modelo

Sea $y = f(x)$ en el sentido de Goldberger (1991). Asumiendo una forma lineal, se tiene:

$$E(y|x_{i2}) = \beta_1 + \beta_2 x_{i2}, \quad i = 1, \dots, N \quad (1)$$

conocida como **FRP**. Dada la inexactitud, el **error** se define por:

$$u_i = y_i - E(y|x_{i2}) \quad (2)$$

Reemplazando, se tiene el modelo de regresión lineal simple:

$$y_i = \beta_1 + \beta_2 x_{i2} + u_i \quad (3)$$

El modelo

El análogo muestral, la **FRM**, es

$$\hat{y}_i = \hat{\beta}_1 + \hat{\beta}_2 x_{i2}, \quad i = 1, \dots, n \quad (4)$$

El **residuo** se escribe como:

$$\hat{u}_i = y_i - \hat{y}_i \quad (5)$$

Reemplazando,

$$y_i = \hat{\beta}_1 + \hat{\beta}_2 x_{i2} + \hat{u}_i \quad (6)$$

¿Qué miden los estimadores?

El modelo

Métodos de estimación:

1. Mínimo Cuadrados Ordinarios (OLS).
2. Mínimos Cuadrados Ponderados (WLS).
3. Mínimos Cuadrados Generalizados (GLS): FGLS y NFGLS.
4. Máxima Verosimilitud (ML).
5. Método Generalizado de Momentos (GMM).
6. Métodos de regularización: Ridge y Lasso.
7. Otros

OLS minimiza la suma cuadrática de los residuos:

$$\min_{\hat{u}} \sum_{i=1}^n (\hat{u}_i)^2 = \sum_{i=1}^n (y_i - \hat{\beta}_1 - \hat{\beta}_2 x_{i2})^2 \quad (7)$$

FOC:

$$\hat{\beta}_1 : -2 \sum (y_i - \hat{\beta}_1 - \hat{\beta}_2 x_{i2}) = 0 \quad (8)$$

$$\hat{\beta}_2 : -2 \sum (y_i - \hat{\beta}_1 - \hat{\beta}_2 x_{i2})(x_{i2}) = 0 \quad (9)$$

OLS

Los estimadores de OLS (LSE) son:

$$\hat{\beta}_1 = \bar{y} - \hat{\beta}_2 \bar{x}_2 \quad (10)$$

$$\hat{\beta}_2 = \frac{\sum y_i \sum x_{i2} - n \sum y_i x_{i2}}{(\sum x_{i2})^2 - n \sum x_{i2}^2} \quad (11)$$

Alternativas:

$$\hat{\beta}_2 = \frac{\sum (x_{i2} - \bar{x}_2)(y_i - \bar{y})}{\sum (x_{i2} - \bar{x}_2)^2} \quad (12)$$

$$\hat{\beta}_2 = \frac{s_{xy}}{s_x^2} \quad (13)$$

$$\hat{\beta}_2 = r \frac{s_y}{s_x} \quad (14)$$

OLS



Propiedades numéricas OLS:

1. LSE son estimadores puntuales.
2. $\sum \hat{u}_i = 0$.
3. $\bar{\hat{y}}_i = \bar{y}$.
4. $\bar{\hat{u}}_i = 0$.
5. $\sum \hat{u}_i x_{i2} = cov(\hat{u}_i, x_{i2}) = 0$.
6. $\sum \underline{\hat{y}}_i \hat{u}_i = cov(\underline{\hat{y}}_i, \hat{u}_i) = 0$, donde $\underline{y}_i = y_i - \bar{y}$.

Ejemplo 1

Sea la información de 9 firmas sobre ventas y publicidad (en miles de soles). Plantear el modelo, estimar e interpretar.

i	publicidad	ventas
1	2	25
2	3	30
3	4	34
4	5	40
5	6	45
6	7	50
7	8	54
8	9	60

Supuestos (Gauss)

1. Linealidad en los parámetros.
2. Regresor fijo: $cov(x_{i2}, u_i) = 0$.
3. $E(u_i|x_{i2}) = 0 \rightarrow E(u_i) = 0$.
4. Homoscedasticidad: $var(u_i|x_{i2}) = \sigma^2$.
5. No autocorrelación: $cov(u_i, u_j|x_i, x_j) = 0, i \neq j$.
6. n grande.
7. No *outliers*.

Bajo los supuestos dados, se tiene las siguientes propiedades estadísticas:

1. Linealidad: los LSE son una función lineal de la v.a y .
2. Insesgadez:

$$E(\hat{\beta}_j) = \beta_j, \quad \forall j = 1, 2 \quad (15)$$

3. Eficiencia: varianza mínima.

El análisis de varianza (ANOVA) en *regression analysis* comprende SS y MS:

$$SCT = SCE + SCR \quad (16)$$

la cual se puede deducir de (25), donde $y_i = \hat{y}_i + \hat{u}_i$. Véase más detalles en ?.

1. Coeficiente de determinación:

$$R^2 = \frac{SCE}{SCT}, \quad SCE = \sum (\hat{y}_i - \bar{y})^2, \quad SCT = \sum (y_i - \bar{y})^2$$

2. **Root mean squared error** (RMSE) o error estándar de regresión:

$$ee = \hat{\sigma}_{\hat{u}}, \quad \hat{\sigma}_{\hat{u}}^2 = \frac{\sum \hat{u}_i^2}{n-1}$$

donde $\hat{\sigma}_{\hat{u}}^2$ es conocido como **mean squared error** (MSE). ¿Y el MAE?

Modelos especiales

Modelo	Forma funcional	Efecto marginal	Elasticidad
Lineal	$y_i = \beta_1 + \beta_2 x_{i2}$	β_2	$\beta_2 \frac{x_{i2}}{y_i}$
Lin-Log	$y_i = \beta_1 + \beta_2 \ln x_{i2}$	$\frac{\beta_2}{x_{i2}}$	$\frac{\beta_2}{y_i}$
Log-Lin	$\ln y_i = \beta_1 + \beta_2 x_{i2}$	$\beta_2 y_i$	$\beta_2 x_{i2}$
Log-Log	$\ln y_i = \beta_1 + \beta_2 \ln x_{i2}$	$\frac{\beta_2 y_i}{x_{i2}}$	β_2
Cuadrática	$y_i = \beta_1 + \beta_2 x_{i2} + \beta_3 x_{i2}^2$	$\beta_2 + 2\beta_3 x_{i2}$	$\frac{(\beta_2 + 2\beta_3 x_{i2})x_{i2}}{y_i}$
Recíproca	$y_i = \beta_1 + \beta_2 \left(\frac{1}{x_{i2}} \right)$	$-\frac{\beta_2}{x_{i2}^2}$	$-\frac{\beta_2}{y_i x_{i2}}$

Regresión lineal múltiple

El modelo

Sea el conjunto de k variables que conforman un hiperplano, $\{x_1, x_2, \dots, x_k\}$, el MRLG se escribe:

$$y_i = \beta_1 + \beta_2 x_{i2} + \dots + \beta_k x_{ik} + u_i, \quad i = 1, \dots, N \quad (17)$$

En forma compacta,

$$\begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ \vdots \\ y_N \end{bmatrix} = \begin{bmatrix} 1 & x_{12} & x_{13} & \cdots & x_{1k} \\ 1 & x_{22} & x_{22} & \cdots & x_{2k} \\ 1 & x_{32} & x_{33} & \cdots & x_{3k} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{N2} & x_{NN} & \cdots & x_{Nk} \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \\ \vdots \\ \beta_k \end{bmatrix} + \begin{bmatrix} u_1 \\ u_2 \\ u_3 \\ \vdots \\ u_N \end{bmatrix}$$

El modelo

En forma resumida,

$$y = X\beta + u \quad (18)$$

$$y_i = x_i'\beta + u_i \quad (19)$$

Por su lado, bajo la FRM, los análogos muestrales de (18) y (19) serán:

$$y = X\hat{\beta} + \hat{u} \quad (20)$$

$$y_i = x_i'\hat{\beta} + \hat{u}_i \quad (21)$$

con predicción $\hat{y} = X\hat{\beta}$ y $\hat{y}_i = x_i'\hat{\beta}$, respectivamente.

De (20), el objetivo LS:

$$\begin{aligned}\min \hat{u}'\hat{u} &= (y - X\hat{\beta})'(y - X\hat{\beta}) \\ &= (y' - \hat{\beta}'X')(y - X\hat{\beta}) \\ &= y'y - \hat{\beta}'X'y - y'X\hat{\beta} + \hat{\beta}'X'X\hat{\beta} \\ &= y'y - 2y'X\hat{\beta} + \hat{\beta}'X'X\hat{\beta}\end{aligned}$$

$$\frac{\partial(\cdot)}{\partial\hat{\beta}} = -2X'y + 2X'X\hat{\beta} = 0 \quad (22)$$

$$\hat{\beta}_{OLS} = (X'X)^{-1}(X'y) \quad (23)$$

Alternativamente, de (21):

$$\begin{aligned}\min \sum \hat{u}_i^2 &= \sum (y_i - x_i' \hat{\beta})^2 \\ &= \sum (y_i^2 - 2y_i x_i' \hat{\beta} + \hat{\beta}' x_i x_i' \hat{\beta})\end{aligned}$$

$$\frac{\partial(\cdot)}{\partial \hat{\beta}} = -2 \sum x_i y_i + 2 \sum x_i x_i' \hat{\beta} = 0 \quad (24)$$

$$\hat{\beta}_{OLS} = \left(\sum x_i x_i' \right)^{-1} \sum x_i y_i \quad (25)$$

Supuestos (Gauss)

1. Linealidad en los parámetros.
2. Matriz de regresores fijo: $E(x_i u_i) = 0$.
3. $E(u_i | x_i) = 0 \rightarrow E(u_i) = 0$.
4. Perturbaciones esféricas: $E(u_i^2) = \sigma^2 I_n$.
5. No multicolinealidad: $\text{ran}(X) = k$.

Supuesto de normalidad

Los errores siguen una distribución de probabilidad normal multivariante:

$$u_i \sim N(0, \sigma^2 I_n) \quad (26)$$

Teorema de Gauss-Markov

Los LSE son **MELI** (ELIO).

- Muestras pequeñas
 - Linealidad
 - Insesgamiento: $E(\hat{\beta}) = \beta$
 - Eficiencia: $var(\hat{\beta}) = \hat{\sigma}^2(\sum x_i x_i')^{-1}$
- Muestras grandes
 - Consistencia: $\underset{n \rightarrow \infty}{plim} \hat{\beta} = \beta$
 - Normalidad asintótica: $\sqrt{n}(\hat{\beta} - \beta) \sim N[0, \sigma^2(\frac{X'X}{n})^{-1}]$

Evaluación de modelos

Bondad de ajuste

1. Coeficiente de determinación:

$$R^2 = \frac{SCE}{SCT}, \quad SCT = y'y - n\bar{y}^2, \quad SCE = \hat{y}'\hat{y} - n\bar{y}^2$$

2. R^2 ajustado (Henri Theil):

$$\hat{R}^2 = 1 - \frac{\hat{u}'\hat{u}/(n-k)}{y'y - n\bar{y}^2/(n-1)}$$

3. RMSE o error estándar de regresión:

$$ee = \hat{\sigma}_{\hat{u}}, \quad \hat{\sigma}_{\hat{u}}^2 = \frac{\hat{u}'\hat{u}}{n-k}$$

Bondad de ajuste

Estadísticos de comparación:

1. AIC:

$$\ln \left(\frac{\hat{u}'\hat{u}}{n} \right) + \frac{2k}{n}$$

2. BIC:

$$\ln \left(\frac{\hat{u}'\hat{u}}{n} \right) + \frac{k}{n} \ln(n)$$

Pruebas estadísticas

Violación de supuestos:

- Multicolinealidad.
- Heterocedasticidad.
- Autocorrelación.
- Endogeneidad.

Pruebas estadísticas

Problemas de especificación:

- Omisión de variables relevantes.
- Inclusión de variables irrelevantes.
- Forma funcional incorrecta.

References

Goldberger, A. S. (1991). *A Course in Econometrics*. Harvard University Press, Cambridge, MA.